

Informe Final – Proyecto Integrador

❖ Contexto y objetivo

El proyecto analiza un dataset de usuarios de una plataforma de streaming para identificar patrones de consumo, calidad de datos y relaciones entre variables. El objetivo principal es aplicar técnicas de minería de datos —inspección, limpieza, EDA, escalamiento y PCA— documentando cada decisión con evidencia y comunicando los resultados mediante una aplicación interactiva y este informe.

❖ Dataset y calidad inicial

El dataset original (`streaming\_users\_dirty.json`) contenía 8160 registros y 8 variables: identificador, edad, plan de suscripción, tiempo de visualización mensual (minutos), país, género favorito, fecha de último login y tickets de soporte.

La inspección inicial reveló: valores faltantes, filas completamente duplicadas, inconsistencias en variables categóricas y valores imposibles.

❖ Decisiones de limpieza y preparación

El proceso de limpieza incluyó:

Paso	Decisión	Justificación
1	Eliminar filas completamente duplicadas	No aportan información adicional.
2	Eliminar duplicados por `user_id`	`user_id` debe ser único.
3	Normalizar `subscription_plan`, `country` y `favorite_genre`	Unificar variantes de escritura.
4	Imputar `favorite_genre` con la moda	Mecanismo MCAR; moda para variables categóricas.
5	Eliminar valores imposibles en `age` (<0 o >100)	Valores fuera del dominio real.
6	Eliminar valores negativos y centinela en `monthly_watch_time_mins`	Errores de carga o valores no disponibles.
7	Winsorizar outliers extremos de `monthly_watch_time_mins` (límite IQR k=3.0)	Conservar registros pero reducir impacto de valores extremos.
8	Imputar nulos de `monthly_watch_time_mins` con la mediana	Distribución asimétrica; mediana más robusta.
9	Eliminar tickets negativos y winsorizar valores extremos (IQR k=3.0)	Similar al criterio anterior.
10	Convertir `last_login_date` a fecha y eliminar nulos y fechas futuras	Datos inválidos o inconsistentes.

❖ Hallazgos del análisis exploratorio

El análisis exploratorio (EDA, notebook `03\_eda.ipynb`) respondió a cinco preguntas de análisis:

1. Distribución de edad: Simétrica, media 33.5 años, sin franja etaria dominante.
2. Tiempo de visualización mensual: Asimétrico (skew positivo), mediana 758 min, media 865 min. El usuario típico consume ~12.6 horas al mes.

3. Plan de suscripción y consumo: Diferencia clara y consistente: Premium (1091 min) > Estándar (861 min) > Básico (593 min). El plan está fuertemente asociado al nivel de consumo.

4. Relación edad – tickets de soporte: Coeficiente de Pearson $r \approx 0.005$, indicando ausencia de relación lineal. La edad no predice el uso de soporte.

5. Consistencia geográfica del patrón de consumo: En todos los países, la jerarquía Premium > Estándar > Básico se mantiene sin excepciones, con pequeñas variaciones entre países dentro de cada plan.

❖ Escalamiento y PCA

Para la reducción de dimensionalidad se seleccionaron las tres variables numéricas (`age`, `monthly\_watch\_time\_mins`, `customer\_support\_tickets`) y se estandarizaron con StandardScaler.

Para alcanzar el umbral del 80% de varianza acumulada se requieren los tres componentes, lo que indica que no se logra una reducción dimensional significativa.

❖ Conclusiones y limitaciones

- El plan de suscripción es el factor más influyente en el consumo mensual, con diferencias sistemáticas y consistentes entre planes y países.
 - La edad no muestra relación con el uso de soporte ni con el nivel de consumo.
 - Las variables numéricas son independientes entre sí, por lo que el PCA no permite comprimir la información sin pérdida significativa.
 - El proceso de limpieza fue riguroso y documentado, aunque la eliminación de registros (13.4%) podría introducir sesgo de selección.

Dentro de las limitaciones podemos mencionar ausencia de variables contextuales (dispositivo, hora de uso, historial de contenido), que limitan la profundidad del análisis, que las asociaciones observadas no implican causalidad y que la independencia de las variables numéricas limita la utilidad del PCA para reducir dimensionalidad.

Como mejoras futuras se podría incorporar datos longitudinales para analizar evolución del consumo y retención, aplicar técnicas de clustering para identificar segmentos de usuarios con comportamientos similares e integrar variables como género de contenido preferido o tipo de dispositivo para enriquecer el perfil de usuario.

Repositorio: [https://github.com/tu-usuario/PI_Mineria_Datos_1](https://github.com/tu-usuario/PI_Mineria_Datos_1)

Aplicación Streamlit: <https://eugerocha-md-pi.streamlit.app/>